

Stochastische Signale

WAHRSCHEINLICHKEITSRÄUME:

Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$ besteht aus:

Ergebnismenge Ω :

$\Omega = \{\omega_1, \omega_2, \dots\}$: Menge aller möglichen Ergebnisse.

Ereignisalgebra $\mathcal{F}$:

$\mathcal{F} = \{A_1, A_2, \dots\}$: Menge von Ereignissen $A_i \subseteq \Omega$.

→ **Eigenschaften:**

• $\Omega \in \mathcal{F}$

• $A_i \in \mathcal{F} \Rightarrow A_i^c \in \mathcal{F}$

• $A_1, \dots, A_k \in \mathcal{F} \Rightarrow \bigcup_{i=1}^k A_i \in \mathcal{F}$

• Impliziert: $\emptyset \in \mathcal{F}$ ($\Omega^c = \emptyset$) • $A_i \setminus A_k \in \mathcal{F}$ • $\bigcap_{i=1}^k A_i \in \mathcal{F}$

→ **Größe:**

$|\mathcal{F}| \geq 2^{\text{Anzahl an disjunkten Teilmengen}}$

Wahrscheinlichkeitsmaß $\mathbb{P}$:

Ordnet jedem Ereignis A eine Wahrscheinlichkeit zu.

→ **Axiome von Kolmogorow:**

• $\mathbb{P}(A) \geq 0 \Rightarrow \mathbb{P}: \mathcal{F} \rightarrow [0, 1]$

• $\mathbb{P}(\Omega) = 1$

• $\mathbb{P}(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$ wenn: $A_i \cap A_j = \emptyset, \forall i \neq j$

Grundlegende Rechenregeln:

• $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$

• $\mathbb{P}(\emptyset) = 0$ • $\mathbb{P}(\Omega) = 1$

• $\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(A \cap B)$

• $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$

• $\mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cup B)$

• $A \subset B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$

BEDINGTE WAHRSCHEINLICHKEIT:

≠ Der Wahrscheinlichkeit für ein Ereignis A , unter der Bedingung, dass bereits ein anderes Ereignis B eingetreten ist.

• $\mathbb{P}_B(A) = \mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$

Multiplikationssatz und dessen Erweiterung:

$\mathbb{P}(A \cap B) = \mathbb{P}(A|B) \cdot \mathbb{P}(B) = \mathbb{P}(B|A) \cdot \mathbb{P}(A)$

$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A|B \cap C) \cdot \mathbb{P}(B \cap C) = \mathbb{P}(A|B \cap C) \cdot \mathbb{P}(B|C) \cdot \mathbb{P}(C)$

TOTALE WAHRSCHEINLICHKEIT:



• $\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A|B_i) \cdot \mathbb{P}(B_i)$

Satz von Bayes:

$\mathbb{P}(B_j|A) = \frac{\mathbb{P}(A|B_j) \cdot \mathbb{P}(B_j)}{\sum_{i=1}^n \mathbb{P}(A|B_i) \cdot \mathbb{P}(B_i)}$

$\mathbb{P}(B_j|A) = \frac{\mathbb{P}(A|B_j) \cdot \mathbb{P}(B_j)}{\mathbb{P}(A)}$

STOCHASTISCHE UNABHÄNGIGKEIT:

Zwei Ereignisse A und B sind stochastisch unabhängig, wenn das Eintreten von A die Wahrscheinlichkeit von B nicht beeinflusst.

• $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B) \Leftrightarrow \mathbb{P}(A|B) = \mathbb{P}(A)$

ZUFALLSVARIABLEN


→ **Definition:** $A \subset \Omega$ oder $A \in \mathcal{F}$

$X: \Omega \rightarrow \Omega'$, $\omega \mapsto X(\omega)$ heißt Zufallsvariable, wenn

für jedes $A' \in \mathcal{F}'$ ein $A \in \mathcal{F}$ existiert, sodass

$A = \{\omega \in \Omega | X(\omega) \in A'\}$


→ **Beispiel:** 2-mal Würfel und Augenzahl addieren



WAHRSCHEINLICHKEITSVERTEILUNGEN

Kumulative Verteilungsfunktion: (CDF bzw. KVF)

$F_X(x) = \mathbb{P}(X \leq x)$; X : Zufallsvariable; x : Realisierung



$F_X(x) = P(\{X \leq x\})$
 $P(\{a < X \leq b\}) = F_X(b) - F_X(a)$
 $P(\{X > c\}) = 1 - F_X(c)$

→ **Eigenschaften:**

• $F_X(x)$ monoton wachsend und rechtsseitig stetig

• $\lim_{x \rightarrow -\infty} F_X(x) = 0$; $\lim_{x \rightarrow \infty} F_X(x) = 1$

• $F_X(x) \geq 0$

Diskrete ZV:

$\sum_n P(X=x) = 1$

→ **Wahrs.massenfkt:** PMF

• $p_X(x) = \mathbb{P}(\{X=x\})$

→ **Kumula. Vert.fkt:** CDF

• $F_X(x) = \sum_{k \leq x} p_X(k)$

→ **Anderes zu Stetigen ZV:**

• $F_X(b) - F_X(a) = \int_a^b f_X(x) dx$

• $\mathbb{P}(\{X(a) < X \leq X(b)\}) = \int_a^b f_X(x) dx = 0$ • $\int_{-\infty}^{\infty} f_X(x) dx = 1$

Stetige ZV:

→ **Wahrs.dichtefkt:** PDF

• $f_X(x) = \frac{d}{dx} F_X(x)$

→ **Kumula. Vert.fkt:** CDF

• $F_X(x) = \int_{-\infty}^x f_X(\xi) d\xi$

BEDINGTE ZUFALLSVARIABLEN

→ **Gegebenes Ereignis A :** $F_{X|A}(x) = \mathbb{P}(\{X \leq x | A\})$

→ **Gegebene ZV Y :**

• $F_{X|Y}(x|y) = \mathbb{P}(\{X \leq x | Y=y\})$

• $p_{X|Y}(x|y) = \frac{p_{X,Y}(x,y)}{p_Y(y)}$ • $f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$


MEHRDM. ZUFALLSVARIABLEN

Gegeben sind n Zufallsvariablen $X_1, X_2, \dots, X_n$

Mehrdimensionale CDF (KVF)

• $F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \mathbb{P}(\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n\})$

• $F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(A) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f_{X_1, X_2}(\xi_1, \xi_2) d\xi_1 d\xi_2$



diskret (PMF):

$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \mathbb{P}(\{X_1 = x_1, \dots, X_n = x_n\})$


stetig (PDF):

$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \frac{\partial^n}{\partial x_1 \dots \partial x_n} F_{X_1, \dots, X_n}(x_1, \dots, x_n)$

$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f_{X_1, \dots, X_n}(\xi_1, \dots, \xi_n) d\xi_1 \dots d\xi_n$

$F_{X,Y} = F_{Y,X}$

→ **Beispiel:**
 $f_{x,y}(x,y) = \frac{4}{9} (1 + xy) \quad (x \in [2, 3] \wedge y \in [1, 2])$
 $= 0 \quad (\text{sonst})$



$F_{X,Y}(x,y) = \begin{cases} 0 & \text{, } x,y \in I, IV, VII, VIII, IX \\ \frac{4}{9} \int_2^x \int_1^y (1 + \xi \eta) d\eta d\xi & \text{, } x,y \in V \\ 1 & \text{, } x,y \in III \\ \frac{4}{9} \int_2^x \int_1^y (1 + \xi \eta) d\eta d\xi & \text{, } x,y \in VI \\ \frac{4}{9} \int_2^x \int_1^2 (1 + \xi \eta) d\eta d\xi & \text{, } x,y \in II \end{cases}$

MARGINALISIERUNG

Prinzip: Lasse alle vernachlässigbaren ZV gegen unendlich gehen.

Kumulative Verteilungsfkt. (KVF):

$F_X(x) = \mathbb{P}(\{X \leq x\}) =$

$\mathbb{P}(\{X \leq x, Y\}) = \lim_{y \rightarrow \infty} F_{X,Y}(x,y) = F_{X,Y}(x, \infty)$

$p_{X_1}(x_1) = \sum_{x_2, \dots, x_n} p_{X_1, \dots, X_n}(x_1, \dots, x_n)$

$f_{X_1}(x_1) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_2 \dots dx_n$

UNABHÄNGIGKEIT VON ZV

Zufallsvariablen $X_1, \dots, X_k$ sind stochastisch unabhängig, wenn

• $\mathbb{P}(\{X_1 \leq x_1, \dots, X_n \leq x_n\}) = \prod_{i=1}^n \mathbb{P}(\{X_i \leq x_i\})$

und somit

• $F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n F_{X_i}(x_i)$


• $p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n p_{X_i}(x_i)$

• $f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$

FUNKTIONEN VON ZUFALLSVARIABLEN

$Y = g(X) \rightarrow X \text{ u. } Y \text{ sind nicht sto. unabhängig}$

Transformation mit monoton und differenzierbaren Fkt:



$f_Y(y) = \frac{f_X(x)}{|g'(x)|} \Big|_{x=g^{-1}(y)}$
(⇒ mit Umkehrfunktion: $g^{-1}(y)$)


Transformation mit nur differenzierbaren Funktionen

Strategie: Aufteilen in monotone Funktionen.

Allgemein: $f_Y(y) = \sum_{i=1}^N \frac{f_X(x_i)}{|g'(x_i)|} \Big|_{x_i=g^{-1}(y)} \quad i \in \{1, \dots, N\}$

(x_i sind Nst. von $y - g(x) = 0$)

→ **Beispiel:**



Gegeben:
• Wertebereich: $y \in [0; 1]$
• $g'(x) = 2x$
Daraus folgt:
⇒ $y = x^2 \Rightarrow x_1/2 = \pm \sqrt{y}$
⇒ $f_Y(y) =$
 $= \frac{f_X(x_1)}{|g'(x_1)|} + \frac{f_X(x_2)}{|g'(x_2)|} =$
 $= \frac{1}{2\sqrt{y}} + \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{y}}$

→ **Beispiel für das Intervall einer ZV-Trafo:**

$f_X(x) = \begin{cases} \frac{1}{\sqrt{2}} & 0 < x < \sqrt{2} \\ 0 & \text{sonst} \end{cases}$

$g(x) = \begin{cases} x^2 & x \leq \sqrt{2} \\ 2 & x > \sqrt{2} \end{cases}$


$Y = g(X) \rightarrow [0, 2]$

Lineare Trafo. von ZV:

Sei: $Y = aX + b \Leftrightarrow g(X) = aX + b \Rightarrow f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right)$

$F_Y(y) = \begin{cases} F_X\left(\frac{y-b}{a}\right) & a > 0 \\ 1 - F_X\left(\frac{y-b}{a}\right) & a < 0 \end{cases}$

Summe unabhängiger ZV:



X & Y sind stochastisch unabhängig: $Z = X + Y$

$F_Z(z) = \mathbb{P}(\{Z \leq z\})$

⇒ $f_Z(z) = \mathbb{P}(Z = z) = (f_X * f_Y)(z) = \int_{-\infty}^{\infty} f_X(z-y) f_Y(y) dy$

STOCHASTISCHE STANDARDMODELLE

Diskrete Modelle

• Diskrete Gleichverteilung

• Geometrische Verteilung

• Bernoulli-Verteilung

• Binominalverteilung

• Poisson-Verteilung

Gedächtnislosigkeit:

ZV ist gedächtnislos, falls

$\mathbb{P}(\{X > a+b\} | \{X > a\}) = \mathbb{P}(\{X > b\})$

stetige Modelle


• Gleichverteilung

• Exponentialverteilung

• Gauß/Normalverteilung

Geometrische Verteilung: diskret/gedächtnislos

$p_X(k) = \begin{cases} p(1-p)^{k-1}, & k = 1, 2, 3, \dots \\ 0, & \text{sonst} \end{cases}$
 $F_X(k) = \begin{cases} 0, & k < 1 \\ 1 - (1-p)^k, & k = 1, 2, 3, \dots \\ 1, & \text{sonst} \end{cases}$



→ **Erwartungswert:**


$\mathbb{E}[X] = \frac{1}{p}$

→ **Charakteristische Fkt:**

$\varphi_X(\omega) = \frac{pe^{i\omega}}{1 - (1-p)e^{i\omega}}$

Exponentialverteilung: stetig/gedächtnislos

→ **Erwartungswert:**
 $\mathbb{E}[X] = \frac{1}{p}$
→ **Charakteristische Fkt:**
 $\varphi_X(\omega) = \frac{pe^{i\omega}}{1 - (1-p)e^{i\omega}}$
→ **Varianz:**
 $\text{Var}[X] = \frac{1-p}{p^2}$



→ **Erwartungswert:**

$\mathbb{E}[X] = \frac{1}{2}$


→ **Charakteristische Fkt:**

$\varphi_X(\omega) = \frac{1}{2} \frac{e^{i\omega}}{1 - \frac{1}{2}e^{i\omega}}$

Normalverteilung: stetig

$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \frac{(x-\mu)^2}{2\sigma^2}$

$F_X(x) = \frac{1}{2} \left[1 + \text{erf}\left(\frac{x-\mu}{\sigma\sqrt{2}}\right) \right] = \Phi\left(\frac{x-\mu}{\sigma}\right)$



→ **Erwartungswert:**

$\mathbb{E}[X] = \mu$

→ **Charakteristische Fkt:**

$\varphi_X(\omega) = e^{i\omega\mu - \frac{1}{2}\sigma^2\omega^2}$

→ **Eigenschaften:** symmetrisch, bei $x = \mu$ maximal

$X \sim N(\mu, \sigma)$

ERWARTUNGSWERT & VARIANZ

Erwartungswert: mittlerer Wert einer ZV, $\mathbb{E}[X] = \mu_X$

$\mathbb{E}[X] = \sum_{x \in \Omega'} x \cdot p_X(x)$ diskrete Zufallsvariable

$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$ stetige Zufallsvariable

→ **Eigenschaften:**

Linearität: $\mathbb{E}[\alpha X + \beta Y] = \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y] = \alpha \mu + \beta \eta$

Monotonie: $X \leq Y \Rightarrow \mathbb{E}[X] \leq \mathbb{E}[Y]$

• $\mathbb{E}[a] = a$

• $\mathbb{E}[-X] = -\mathbb{E}[X]$

• $\mathbb{E}[X + \beta] = \mathbb{E}[X] + \beta$

• bei einer Fkt: $Y = g(x)$ vereinfachen durch einsetzen!

$\mathbb{E}[XY] = \int \int xy f_{X,Y}(x,y) dx dy$

• sto. unabhängig, dann: $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$

! $\mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[XY] \Rightarrow$ unabh. !

Varianz: Maß für die Abweichung vom Erwartungswert

$\text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$

→ **Eigenschaften:**

• $\text{Var}[-X] = \text{Var}[X]$

• $\text{Var}[\alpha X] = \alpha^2 \text{Var}[X], \alpha \in \mathbb{R}$

• $\text{Var}[a] = 0$

• $\text{Var}[\alpha X + \beta] = \alpha^2 \text{Var}[X]$

• $\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y] + 2\text{Cov}[X, Y]$

• $\text{Var}[X - Y] = \text{Var}[X] + \text{Var}[Y] - 2\text{Cov}[X, Y]$

Kovarianz: linearer Zusammenhang zwischen zwei ZV

$\text{Cov}[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$

$\text{Cov}[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$

→ **Eigenschaften:**

ZUFALLS FOLGEN

Definition:

$X_i:\Omega\rightarrow\mathbb{R},\,i\in\mathbb{N}$

Bei $N\rightarrow\infty$ wäre die vollständige Beschreibung über die gemeinsame CDF $F_{X_1,\dots,X_N}(x_1,\dots,x_N)$ sehr komplex.

Vereinfachungsschritt: *Momente 1./2. Ordnung*

Betrachte Erwartungswertfolge, Varianzfolge und

(Auto-)Korrelation/Kovarianz:

- $\mu_X(i)=\mathbb{E}[X_i]$ (**Erwartungswertfolge**)
- $\sigma_X^2(i)=\text{Var}[X_i]=\mathbb{E}[X_i^2]-\mathbb{E}[X_i]^2$ (**Varianzfolge**)
- $r_X(k,l)=\mathbb{E}[X_kX_l]$ (**Autokorrelationsfolge**)
- $c_X(k,l)=\text{Cov}[X_k,X_l]=r_X(k,l)-\mu_X(k)\mu_X(l)$
 $=\mathbb{E}[(X_k-\mathbb{E}[X_k])(X_l-\mathbb{E}[X_l])]$ (**Autokovarianzfolge**)

Zwei Zufallsfolgen X_i,Y_i :

- $r_{XY}(k,l)=\mathbb{E}[X_kY_l]$ (**Kreuzkorrelationsfolge**)
- $c_{XY}(k,l)=\text{Cov}[X_k,Y_l]=r_{XY}(k,l)-\mu_X(k)\mu_Y(l)$
 $=\mathbb{E}[(X_k-\mathbb{E}[X_k])(Y_l-\mathbb{E}[Y_l])]$ (**Kreuzkovarianzfolge**)

Orthogonal: $r_{XY}(k,l)=0$ **Unkorreliert:** $c_{XY}(k,l)=0$

i.i.d.-Folge: *unabhängig und identisch verteilt*

X_i i.i.d. $\Rightarrow \mathbb{E}[X_i]=\mu,\,\text{Var}[X_i]=\sigma^2,\,\text{Cov}[X_i,X_j]=0\,(i\neq j)$

Stationarität:

Streng stationar:

$F_{X(i_1,\dots,X_{im})}(x_1,\dots,x_m)=F_{X(i_1+sk,\dots,X_{im}+sk)}(x_1,\dots,x_m)$

WSS:

$\mu_X(i)=\mu$ konstant, $r_X(k,l)=r_X(k-l)$,

$c_X(k,l)=c_X(k-l)$

$\rightarrow$ **wichtige Relationen:**

stationär $\Rightarrow$ WSS

WSS $\Rightarrow$ Stationär

Random Walk:

Definition: mathematisches Modell für eine Folge zufälliger Schritte, um zufällige Prozesse/Bewegungen zu modellieren.

Grundkonzept: Start bei einem Punkt; pro Schritt entweder vorwärts $(+\delta)$ mit Wkt. p oder rückwärts $(-\delta)$ mit Wkt. $1-p$.

Mathematisch: $n\in\mathbb{N}$ Schritte, $X_i\in\{+\delta,-\delta\}$ (i.i.d.)

$S_n=\sum_{i=1}^nX_i$, für kleine und große n nicht stationär

$\bullet \mathbb{P}(\{X_i=+\delta\})=p,\quad \bullet \mathbb{P}(\{X_i=-\delta\})=1-p$

$\bullet \text{Var}[X_i]=(2p-1)\delta,\quad \bullet \text{Var}[X_i]=4p(1-p)\delta^2$

$\bullet \mu_S(n)=\mathbb{E}[S_n]=n(2p-1)\delta$

$\bullet \sigma_S^2(n)=\text{Var}[S_n]=4np(1-p)\delta^2$

Für $p=\frac{1}{2}$ gilt: $\mu_S(n)=0$ und $\sigma_S^2(n)=n\delta^2$.

MARKOVKETTEN UND

BEDINGTE UNABHÄNGIGKEIT

Markov-Ungleichung:

Abschätzung für große Ausschläge einer ZV:

$\mathbb{P}(\{|X|\geq a\})\leq \frac{\mathbb{E}[|X|]}{a},\quad a>0$

Tschebyschow-Ungleichung:

$\mathbb{P}(\{|X-\mathbb{E}[X]|\geq a\})\leq \frac{\text{Var}[X]}{a^2},\quad a>0$

$\Rightarrow \mathbb{P}(\{|X-\mathbb{E}[X]|<a\})\geq 1-\frac{\text{Var}[X]}{a^2}$

Bedingte Unabhängigkeit:

Ereignisse A,C sind bedingt unabhängig bzgl. B , wenn

$\mathbb{P}(A\cap C|B)=\mathbb{P}(A|B)\mathbb{P}(C|B)$

$\Leftrightarrow \mathbb{P}(A|B\cap C)=\mathbb{P}(A|B)$

$\Leftrightarrow \mathbb{P}(C|B\cap A)=\mathbb{P}(C|B)$

Achtung: i.A. gilt nicht $\mathbb{P}(A\cap C)=\mathbb{P}(A)\mathbb{P}(C)$.

Für Zufallsvariablen/pdf/pmf:

$p_{X,Z|Y}(x,z|y)=p_{X|Y}(x|y)p_{Z|Y}(z|y)$

$p_{Z|Y,X}(z|y,x)=p_{Z|Y}(z|y)$

$f_{Z|Y,X}(z|y,x)=f_{Z|Y}(z|y)$

$f_{X,Z|Y}(x,z|y)=f_{X|Y}(x|y)\cdot f_{Z|Y}(z|y)$

$\Rightarrow \frac{f_{X_1,X_2,X_3}(x_1,x_2,x_3)}{f_{X_1,X_2}(x_1,x_2)}=\frac{f_{X_2,X_3}(x_2,x_3)}{f_{X_2}(x_2)}$

$\Rightarrow \frac{f_{X_1,X_2,X_3}(x_1,x_2,x_3)}{f_{X_2,X_3}(x_2,x_3)}=\frac{f_{X_1,X_2}(x_1,x_2)}{f_{X_2}(x_2)}$

Markov-Eigenschaft:

$\mathbb{P}(X_{n+1}=x_{n+1}|X_n,\dots,X_1)=\mathbb{P}(X_{n+1}=x_{n+1}|X_n)$

Beispiel (1. Ordnung): $f_{X_3|X_2,X_1}(x_3|x_2,x_1)=f_{X_3|X_2}(x_3|x_2)$

Homogene Markovkette:

$p_{ij}=\mathbb{P}(X_{n+1}=j|X_n=i)$ ist unabhängig vom Index n .

Zustandsübergang / Matrix:

Übergangsmatrix: $\Pi=[p_{ij}],\,p_{ij}\in[0,1],\,\sum_jp_{ij}=1$

m -Schritt-Übergänge: $p_{ij}^{(m)}=\mathbb{P}(X_{n+m}=j|X_n=i)=[\Pi^m]_{ij}$

Zustandsvektor:

$\underline{p}_{n+1}=\underline{p}_n\Pi,\quad \underline{p}_{n+m}=\underline{p}_n\Pi^m$

Stationäre Verteilung:

$\underline{\pi}=\underline{\pi}\Pi,\quad \sum_i\pi_i=1$

Bei endlichem, irreduziblem und aperiodischem Zustandsraum ist

$\underline{\pi}$ eindeutig und $\underline{p}_{-n}\rightarrow\underline{\pi}$.

REELLE ZUFALLSPROZESSE

Grundgrößen:

$\mu_X(t)=\mathbb{E}[X_t]$

$\sigma_X^2(t)=\text{Var}[X_t]$

$r_X(t,s)=\mathbb{E}[X_tX_s]$

$c_X(t,s)=\text{Cov}[X_t,X_s]=r_X(t,s)-\mu_X(t)\mu_X(s)$

Gemeinsame Prozesse X_i,Y_i :

$r_{XY}(t,s)=\mathbb{E}[X_tY_s]$

$c_{XY}(t,s)=r_{XY}(t,s)-\mu_X(t)\mu_Y(s)$

WSS-Prozess:

$\mu_X(t)=\mu_X$

konstant, $r_X(t,s)=r_X(t-s)$,

$c_X(t,s)=c_X(t-s)$

Orthogonalität / Unkorreliertheit:

Orthogonal: $r_{XY}(t,s)=0$

Unkorreliert: $c_{XY}(t,s)=0$

Wiener-Prozess (kurz):

$W_t\sim\mathcal{N}(0,\sigma^2t),\quad \mathbb{E}[W_t]=0,\quad \text{Var}[W_t]=\sigma^2t,$

$r_W(s,t)=\sigma^2\min(s,t)$ und unabhängige Inkremente.

POISSON PROZESS

Definition:

N_t : Anzahl Ereignisse in $[0,t]$ mit Rate $\lambda>0$.

$N_t\sim\text{Pois}(\lambda t)$

$\mathbb{P}(N_t=n)=\frac{(\lambda t)^n}{n!}\text{e}^{-\lambda t},\,n\in\mathbb{N}_0$

$\rightarrow$ **Eigenschaften:**

$\bullet \mathbb{E}[N_t]=\lambda t$

$\bullet \text{Var}[N_t]=\lambda t$

$\bullet r_N(s,t)=\lambda\min(s,t)+\lambda^2st$

$\bullet c_N(s,t)=\lambda\min(s,t)$

$\bullet$ **Inkrementesindunabhängigundstationar**

$\bullet X_t\sim\text{Exp}(\lambda)$ (Wartezeiten, i.i.d.)

LEISTUNGSDICHTESPEKTRUM UND

LTI-SYSTEME

LTI-System:

$y(t)=(h*x)(t)=\int_{-\infty}^{\infty}h(\tau)x(t-\tau)d\tau$

$Y(f)=H(f)X(f)$

Bei WSS-Eingang:

$\mu_Y=\mu_X\int h(t)dt=\mu_XH(0)$

$r_{YY}(\tau)=(h*h*r_{XX})(\tau),\,h(t)=h(-t)$

Leistungsdichte (LDS):

$S_{YY}(f)=|H(f)|^2S_{XX}(f)$

$S_{XY}(f)=H(f)S_{XX}(f),\quad S_{YX}(f)=H^*(f)S_{XX}(f)$

Allgemein für WSS-Prozesse:

$\bullet S_X(f)\geq 0$

$\bullet S_X(-f)=S_X(f)$ für reelle Prozesse

$\bullet \int_{-\infty}^{\infty}S_X(f)df=\text{Var}[X]+\mu_X^2$