Stochastische Signale

Wahrscheinlichkeitsräume:

Wahrscheinlichkeitsraum $(\Omega, \mathbb{F}, P)$ besteht aus:

Ergebnismenge Ω:

$\Omega = \{\omega_1, \omega_2, \ldots\}$: Menge aller möglichen Ergebnisse.

Ereignisalgebra $\mathbb{F}$:

$\mathbb{F} = \{A_1, A_2, \ldots\}$: Menge von Ereignissen $A_i \subseteq \Omega$.

→ **Eigenschaften:**

- $\Omega \in \mathbb{F}$
- $A_i \in \mathbb{F} \Rightarrow A_i^c \in \mathbb{F}$
- $A_1, \ldots, A_k \in \mathbb{F} \Rightarrow \cup_{i=1}^k A_i \in \mathbb{F}$

- Impliziert: • $\emptyset \in \mathbb{F}$ $(\Omega^c = \emptyset)$ • $A_i \setminus A_k \in \mathbb{F}$ • $\cap_{i=1}^k \in \mathbb{F}$

→ **Größe:**

- $|\mathbb{F}| \hat{=} 2^{\text{Anzahl an disjunkter Teilmengen}}$

Wahrscheinlichkeitsmaß P:

Ordnet jedem Ereignis A eine Wahrscheinlichkeit zu.

→ **Axiome von Kolmogorow:**

- $P(A) \geq 0 \Rightarrow P: \mathbb{F} \mapsto [0,1]$
- $P(\Omega) = 1$
- $P(\cup_{i=1}^\infty A_i) = \sum_{i=1}^\infty P(A_i)$ wenn: $\overbrace{A_i \cap A_j = \emptyset, \forall i \neq j}^{\text{(disjunkt)}}$

Grundlegende Rechenregeln:

- $P(A^c) = 1 - P(A)$
- $P(\emptyset) = 0$ • $P(\Omega) = 1$
- $P(A \setminus B) = P(A) - P(A \cap B)$
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- $P(A \cap B) = P(A) + P(B) - P(A \cup B)$
- $A \subset B \Rightarrow P(A) \leq P(B)$

Bedingte Wahrscheinlichkeit:

≙ Der Wahrscheinlichkeit für ein Ereignis A, unter der Bedingung, dass bereits ein anderes Ereignis B eingetreten ist.

- $P_B(A) = P(A|B) = \frac{P(A \cap B)}{P(B)}$

Multiplikationssatz und dessen Erweiterung:

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

$$P(A \cap B \cap C) = P(A|B \cap C) \cdot P(B \cap C) = P(A|B \cap C) \cdot P(B|C) \cdot P(C)$$

Totale Wahrscheinlichkeit:

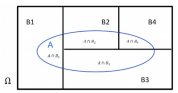

$\Omega = \cup_{i=1}^n B_i$

mit: $B_i \cap B_j = \emptyset$

$P(A \cap B) = P(A|B_i) \cdot P(B_i)$

- $P(A) = \sum_{i=1}^n P(A|B_i) \cdot P(B_i)$

Satz von Bayes:

$$P(B_j|A) = \frac{P(A|B_j) \cdot P(B_j)}{\sum_{i=1}^n P(A|B_i) \cdot P(B_i)}$$

$$P(B_j|A) = \frac{P(A|B_j) \cdot P(B_j)}{P(A)}$$

Stochastische Unabhängigkeit:

Zwei Ereignisse A und B sind stochastisch unabhängig, wenn das Eintreten von A die Wahrscheinlichkeit von B nicht beeinflusst.

- $P(A \cap B) = P(A) \cdot P(B) \Rightarrow P(A|B) = P(A)$

Zufallsvariablen

→ **Definition:** $A \subset \Omega$ oder $A \in \mathbb{F}$

$X: \Omega \to \Omega'$, $\omega \to X(\omega)$ heißt Zufallsvariable, wenn für jedes $A' \in \mathbb{F}'$ ein $A \in \mathbb{F}$ existiert, sodass $A = \{\omega \in \Omega | X(\omega) \in A'\}$

→ **Beispiel:** 2-mal Würfeln und Augenzahl addieren

1,1	1,2	1,3	1,4	1,5	1,6	
2,1	2,2	2,3	2,4	2,5	2,6	
3,1	3,2	3,3	3,4	3,5	3,6	
4,1	4,2	4,3	4,4	4,5	4,6	
5,1	5,2	5,3	5,4	5,5	5,6	
6,1	6,2	6,3	6,4	6,5	6,6	

$X((\omega_1, \omega_2)) = \omega_1 + \omega_2$

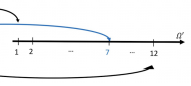

Wahrscheinlichkeitsverteilungen

Kumulative Verteilungsfunktion: *(CDF bzw. KVF)*

$F_X(x) = P(X \leq x)$; X: Zufallsvariable; x: Realisierung

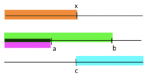

$F_X(x) = P(\{X \leq x\})$

$P(\{a < X \leq b\}) = F_X(b) - F_X(a)$

$P(\{X > c\}) = 1 - F_X(c)$

→ **Eigenschaften:**

- $F_x(x)$ monoton wachsend und rechtsseitig stetig
- $\lim_{x \to \infty} F_x(x) = 0$; $\lim_{x \to \infty} F_x(x) = 1$
- $F_x(x) \geq 0$

Diskrete ZV:

$\sum_{\mathbb{R}} p_X(x) = 1$

→ **Wahrs.massenfkt:** PMF

- $p_X(x) = P(\{X = x\})$

→ **Kumula. Vert.fkt:** CDF

- $F_X(x) = \sum_{k \leq x} p_X(k)$

Stetige ZV:

→ **Wahrs.dichtefkt:** PDF

- $f_X(x) = \frac{d}{dx} F_X(x)$

→ **Kumula. Vert.fkt:** CDF

- $F_X(x) = \int_{-\infty}^x f_X(\xi) d\xi$

→ **Anderes zu Stetigen ZV:**

- $F_X(b) - F_X(a) = \int_a^b f_X(x) dx$
- $P(\{X = a\}) = \int_a^a f_X(x) dx = 0$ • $\int_{-\infty}^\infty f_X(x) dx = 1$

Bedingte Zufallsvariablen

→ **Gegebenes Ereignis A:** $F_{X|A}(x|A) = P(\{X \leq x | A\})$

→ **Gegebene ZV Y:**

- $F_{X|Y}(x|y) = P(\{X \leq x | Y = y\})$
- $p_{X|Y}(x|y) = \frac{p_{X,Y}(x,y)}{p_Y(y)}$ • $f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$

Mehrdim. Zufallsvariablen

Gegeben sind n Zufallsvariablen $X_1, X_2, \ldots, X_n$

Mehrdimensionale CDF (KVF)

- $F_{X_1, \ldots, X_n}(x_1, \ldots, x_n) = P(\{X_1 \leq x_1, X_2 \leq x_2, \ldots, X_n \leq x_n\})$
- $F_{X_1, X_2}(x_1, x_2) = P(A) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f_{X_1, X_2}(\xi, \eta) d\eta d\xi$

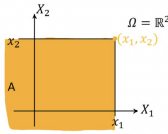

diskret (PMF):

$p_{X_1, \ldots, X_n}(x_1, \ldots, x_n) = P(\{X_1 = x_1, \ldots, X_n = x_n\})$

stetig (PDF):

$f_{X_1, \ldots, X_n}(x_1, \ldots, x_n) = \frac{\partial^n}{\partial x_1, \ldots, \partial x_n} F_{X_1, \ldots, X_n}(x_1, \ldots, x_n)$

$F_{X_1, \ldots, X_n}(x_1, \ldots, x_n) = \int_{-\infty}^{x_n} .. \int_{-\infty}^{x_1} f_{X_1, \ldots, X_n}(\xi_1, \ldots, \xi_n) d\xi_1 .. d\xi_n$

$F_{X,Y} = F_{Y,X}$

→ **Beispiel:**

$f_{X,Y}(x,y) = \frac{4}{19}(1 + xy) \quad (x \in [2,3] \wedge y \in [1,2])$

$= 0 \quad$ (sonst)

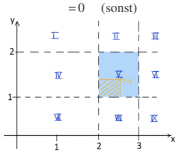

$$F_{X,Y}(x,y) = \begin{cases} 0 & ; x,y \in \text{I, IV, VII, VIII, IX} \\ \frac{4}{19} \int_2^x \int_1^y (1 + \xi\eta) d\eta d\xi & ; x,y \in \text{V} \\ 1 & ; x,y \in \text{III} \\ \frac{4}{19} \int_2^3 \int_1^y (1 + \xi\eta) d\eta d\xi & ; x,y \in \text{VI} \\ \frac{4}{19} \int_2^x \int_1^2 (1 + \xi\eta) d\eta d\xi & ; x,y \in \text{II} \end{cases}$$

Marginalisierung

Prinzip: Lasse alle vernachlässigbaren ZV gegen unendlich gehen.

Kumulative Verteilungsfkt. (KVF):

$F_X(x) = P(\{X \leq x\}) =$

$P(\{X \leq x, Y\}) = \lim_{y \to \infty} F_{X,Y}(x,y) = F_{X,Y}(x, \infty)$

$p_{X_1}(x_1) = \sum_{x_2, \ldots, x_n} p_{X_1, \ldots, X_n}(x_1, \ldots, x_n)$

$f_{X_1}(x_1) = \int_{-\infty}^\infty \cdots \int_{-\infty}^\infty f_{X_1, \ldots, X_n}(x_1, \ldots, x_n) dx_2 \ldots dx_n$

Unabhängigkeit von ZV

Zufallsvariablen $X_1, \ldots, X_i$ sind stochastisch unabhängig, wenn

- $P(\{X_1 \leq x_1, \ldots, X_n \leq x_n\}) = \prod_{i=1}^n P(\{X_i \leq x_i\})$

und somit

- $F_{X_1, \ldots, X_n}(x_1, \ldots, x_n) = \prod_{i=1}^n F_{X_i}(x_i)$
- $p_{X_1, \ldots, X_n}(x_1, \ldots, x_n) = \prod_{i=1}^n p_{X_i}(x_i)$
- $f_{X_1, \ldots, X_n}(x_1, \ldots, x_n) = \prod_{i=1}^n f_{X_i}(x_i)$

Funktionen von Zufallsvariablen

$Y = g(X) \to$ X u. Y sind nicht sto. unabhängig

Transformation mit monoton und differenzierbaren Fkt:

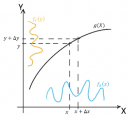

$f_Y(y) = \frac{f_X(x)}{|g'(x)|}\Big|_{x = g^{-1}(y)}$

($\Rightarrow$ mit Umkehrfunktion: $g^{-1}(y)$)

Transformation mit nur differenziebaren Funktionen

Strategie: Aufteilen in monotone Funktionen.

Allgemein: $f_Y(y) = \sum_{i=1}^N \frac{f_X(x_i)}{\left|\frac{dg(x)}{dx}\right|_{x=x_i}}$ $\quad i \in \{1, \ldots, N\}$

(x_i sind Nst. von $y - g(x) = 0$)

→ **Beispiel:**

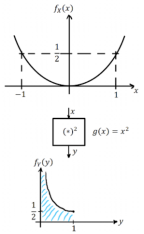

Gegeben:

- Wertebereich: $y \in [0;1]$
- $g'(x) = 2x$

Daraus folgt:

$\Rightarrow \quad y = x^2 \to x_{1/2} = \pm\sqrt{y}$

$\Rightarrow \quad f_Y(y) =$

$= \frac{f_X(x_1)}{|g'(x_1)|} + \frac{f_X(x_2)}{|g'(x_2)|} =$

$= \frac{1}{2\sqrt{y}} + \frac{1}{|-2\sqrt{y}|} = \frac{1}{2\sqrt{y}}$

→ **Beispiel für das Interval einer ZV-Trafo:**

$$f_X(x) = \begin{cases} \frac{1}{\sqrt{2}} & 0 < x < \sqrt{2} \\ 0 & \text{sonst} \end{cases}$$

$$g(x) = \begin{cases} x^2 & x \leq \sqrt{2} \\ 2 & x > \sqrt{2} \end{cases}$$

$Y = g(X) \to [0,2]$

Lineare Trafo. von ZV:

Sei: $Y = aX + b \Longleftrightarrow g(x) = ax + b \Longrightarrow f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right)$

$$F_Y(y) = \begin{cases} F_X\left(\frac{y-b}{a}\right) & a > 0 \\ 1 - F_X\left(\frac{y-b}{a}\right) & a < 0 \end{cases}$$

Summe unabhängiger ZV:

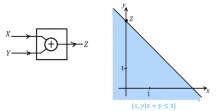

X & Y sind stochastisch unabhängig: $Z = X + Y$

$F_Z(z) = P(\{Z \leq z\})$

$\Longrightarrow f_{Z=X+Y}(z) = (f_X * f_Y)(z) = \int_{-\infty}^\infty f_X(z-y) f_Y dy$

Stochastische Standardmodelle

Diskrete Modelle

- Diskrete Gleichverteilung
- Geometrische Verteilung
- Bernoulliverteilung
- Binominalverteilung
- Poisson-Verteilung

stetige Modelle

- Gleichverteilung
- Exponentialverteilung
- Gauß/Normalverteilung

Gedächtnislosigkeit:

ZV ist gedächtnislos, falls

$P(\{X > a + b\} | \{x > a\}) = P(\{X > b\})$

Gleichverteilung: *stetig/diskret*

diskret: $p_X(x) = \frac{1}{|\Omega|}$ (Münze, Würfel)

stetig: $f_X(x) = \begin{cases} \frac{1}{b-a}, x \in [a,b] \\ 0, \text{sonst} \end{cases}$ $\quad F_X(x) = \begin{cases} 0 & , x < a \\ \frac{x-a}{b-a} & , x \in [a,b] \\ 1 & , x > b \end{cases}$

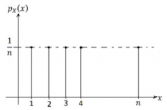

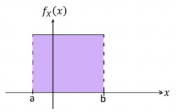

→ **Erwartungswert:**

$E[X] = \frac{a+b}{2}$

→ **Varianz:**

$Var[X] = \frac{(b-a)^2}{12}$

→ **Charackeristische Fkt:**

$\varphi_X(\omega) = \frac{e^{j\omega b} - e^{j\omega a}}{j\omega(b-a)}$

Bernoulliverteilung: *diskret*

$p_X(x) = \begin{cases} 1-p & , x = 0 \\ p & , x = 1 \\ 0 & , \text{sonst} \end{cases}$ $\quad F_X(x) = \begin{cases} 0 & , x < 0 \\ 1-p & , 0 \leq x < 1 \\ 1 & , x \geq 1 \end{cases}$

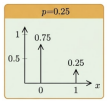

2 Ereignisse: Erfolg/Miserflog

→ **Erwartungswert:**

$E[X] = p$

→ **Varianz:**

$Var[X] = p(1-p)$

→ **Charakteristische Fkt:**

$\varphi_X(\omega) = E[e^{j\omega X}] = (1-p) + pe^{j\omega}$

Binominalverteilung: *diskret*

$p_X(k) = \begin{cases} \binom{n}{k} p^k (1-p)^{n-k} & , k = 0, 1, \ldots, n \\ 0 & , \text{sonst} \end{cases}$

$F_X(k) = \sum_{i=0}^{\lfloor k \rfloor} \binom{n}{i} p^i (1-p)^{n-i}$

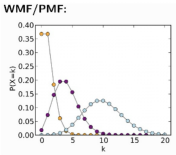

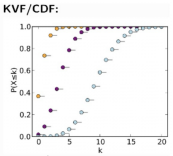

→ **Erwartungswert:**

$E[X] = np$

→ **Varianz:**

$Var[X] = np(1-p)$

→ **Charakteristische Fkt:**

$\varphi_X(\omega) = ((1-p) + pe^{j\omega})^n$

Poisson-Verteilung: *diskret*

$p_X(k) = \begin{cases} e^{-\lambda} \frac{\lambda^k}{k!} & , k = 0, 1, 2, \ldots \\ 0 & , \text{sonst} \end{cases}$

k: Anzahl der Erfolge, p: Erfolgswahrscheinlichkeit

Folge von n Bernoulli-Experimenten.

$F_X(k) = \sum_{i=0}^{\lfloor k \rfloor} e^{-\lambda} \frac{\lambda^i}{i!}$

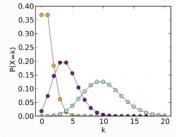

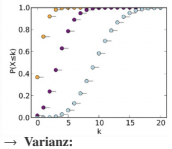

→ **Erwartungswert:**

$E[X] = \lambda$

→ **Varianz:**

$Var[X] = \lambda$

→ **Charakteristische Fkt:**

$\varphi_X(\omega) = \exp(\lambda(e^{j\omega} - 1))$

Geometrische Verteilung: *diskret/gedächtnislos*

$p_X(k) = \begin{cases} p(1-p)^{k-1} & , k = 1, 2, 3, \ldots \\ 0 & , \text{sonst} \end{cases}$

$F_X(k) = \begin{cases} 0 & , k < 1 \\ 1 - (1-p)^k & , k = 1, 2, 3, \ldots \\ 1 & , \text{sonst} \end{cases}$

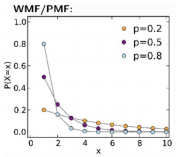

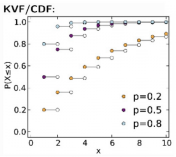

→ **Erwartungswert:**

$E[X] = \frac{1}{p}$

→ **Varianz:**

$Var[X] = \frac{1-p}{p^2}$

→ **Charakteristische Fkt:**

$\varphi_X(\omega) = \frac{pe^{j\omega}}{1 - (1-p)e^{j\omega}}$

Exponentialverteilung: *stetig/gedächtnislos*

$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & , x \geq 0 \\ 0 & , \text{sonst} \end{cases}$

$F_X(x) = \begin{cases} 0 & , x < 0 \\ 1 - e^{-\lambda x} & , x \geq 0 \end{cases}$

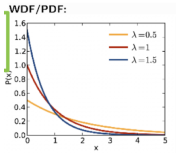

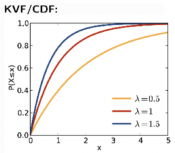

→ **Erwartungswert:**

$E[X] = \frac{1}{\lambda}$

→ **Varianz:**

$Var[X] = \frac{1}{\lambda^2}$

→ **Charakteristische Fkt:**

$\varphi_X(\omega) = \frac{\lambda}{\lambda - j\omega}$

Normalverteilung: *stetig*

$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

$F_X(x) = \frac{1}{2}\left[1 + \text{erf}\left(\frac{x-\mu}{\sigma\sqrt{2}}\right)\right] = \Phi\left(\frac{x-\mu}{\sigma}\right)$

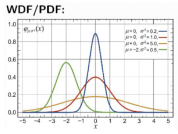

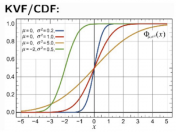

→ **Erwartungswert:**

$E[X] = \mu$

→ **Varianz:**

$Var[X] = \sigma^2$

→ **Charakteristische Fkt:**

$\varphi_X(\omega) = e^{j\omega\mu - \frac{1}{2}\sigma^2\omega^2}$

→ **Eigenschaften:** symmetrisch, bei $x = \mu$ maximal

$X \sim N(\mu, \sigma)$

Erwartungswert & Varianz

Erwartungswert: *mittlerer Wert einer ZV,* $\quad E[X] = \mu_X$

$E[X] = \sum_{x \in \Omega'} x \cdot p_X(x)$ $\quad$ diskrete Zufallsvariable

$E[X] = \underbrace{\int_{-\infty}^\infty x \cdot f_X(x) dx}_{\text{1. Moment}}$ $\quad$ stetige Zufallsvariable

→ **Eigenschaften:**

Linearität: $E[\alpha X + \beta Y] = \alpha E[X] + \beta E[Y] = \alpha\mu + \beta\eta$

Monotonie: $X \leq Y \Rightarrow E[X] \leq E[Y]$

- $E[a] = a$
- $E[-X] = -E[X]$
- $E[X + \beta] = E[X] + \beta$
- bei einer Fkt: $Y = g(x)$ vereinfachen durch einsetzen!

$E[XY] = \iint_{\mathbb{R}^2} xy f_{XY}(x,y) dx dy$

- sto. unabhängig, dann: $\quad E[XY] = E[X]E[Y]$

! $E[X]E[Y] = E[XY] \Rightarrow$ unabh. !

Varianz: *Maß fur die Abweichung vom Erwartungswert*

$Var[X] = E[(X - E[X])^2] = E[X^2] - (E[X])^2$

→ **Eigenschaften:**

- $Var[-X] = Var[X]$
- $Var[aX] = a^2 Var[X]$, $a \in \mathbb{R}$
- $Var[a] = 0$
- $Var[aX + \beta] = a^2 Var[X]$
- $Var[X + Y] = Var[X] + Var[Y] + 2Cov[X,Y]$
- $Var[X - Y] = Var[X] + Var[Y] - 2Cov[X,Y]$

Kovarianz: *linearer Zusammenhang zwischen zwei ZV*

$Cov[X,Y] = E[(X - E[X])(Y - E[Y])]$

$Cov[X,Y] = E[XY] - E[X]E[Y]$

→ **Eigenschaften:**

- $Cov[X,X] = Var[X]$
- $Cov[X,Y] = Cov[Y,X]$
- $Cov[aX + \beta, Y] = aCov[X,Y]$
- $X \perp Y \Rightarrow Cov[X,Y] = 0$ $\quad$ (Umkehrung i.A. falsch)

Korrelationskoeffizient: *normierte Kovarianz*

$\rho_{X,Y} = \frac{Cov[X,Y]}{\sqrt{Var[X]Var[Y]}}$

Es gilt: $\rho_{X,Y} \in [-1, 1]$

- $\rho_{X,Y} < 0$ negativ korreliert,
- $\rho_{X,Y} = 0$ unkorreliert,
- $\rho_{X,Y} > 0$ positiv korreliert.

→ **Unkorreliert vs. orthogonal:**

Unkorreliert: $Cov[X,Y] = 0$

Orthogonal: $E[XY] = 0$

Erzeugend/Charakteristisch Fkt.

Wahrscheinlichkeits-erzeugende Funktion:

$$G_X(z) = E[z^X] = \sum_{k=0}^\infty z^k p_X(k), \quad z \in \mathbb{C}, |z| \leq 1$$

→ **Eigenschaften:**

- $P(X = n) = \frac{1}{n!} \frac{d^n}{dz^n} G_X(z)\Big|_{z=0}$
- $E[X] = \frac{d}{dz} G_X(z)\Big|_{z=1}$
- $E[X^2] - E[X] = \frac{d^2}{dz^2} G_X(z)\Big|_{z=1}$
- $Var[X] = \frac{d^2}{dz^2} G_X(z)\Big|_{z=1} - E[X]^2 + E[X]$
- Wenn nur $G_X(z)$ fur eine diskrete Zufallsvariable bekannt ist, konnen daraus Verteilung, $E[X]$ und $Var[X]$ bestimmt werden.

Momentenerzeugende Funktion:

$$M_X(s) = E[e^{sX}] = \int_{-\infty}^\infty f_X(x) e^{sx} dx = \sum_{k=0}^\infty \frac{s^k}{k!} E[X^k]$$

→ **Eigenschaft:**

- $E[X^n] = \frac{d^n}{ds^n} M_X(s)\Big|_{s=0}$

Charakteristische Funktion: *stetige ZV*

$$\varphi_X(\omega) = E[e^{j\omega X}] = \int_{-\infty}^\infty f_X(x) e^{j\omega x} dx$$

→ **Eigenschaft:**

- $E[X^n] = \frac{1}{j^n} \frac{d^n}{d\omega^n} \varphi_X(\omega)\Big|_{\omega=0}$

Summe unabhangiger ZV:

Sind X, Y unabhangig und $Z = X + Y$, dann gilt:

- $G_Z(z) = G_X(z) \cdot G_Y(z)$
- $M_Z(s) = M_X(s) \cdot M_Y(s)$
- $\varphi_Z(\omega) = \varphi_X(\omega) \cdot \varphi_Y(\omega)$

Zentraler Grenzwertsatz:

Seien X_i i.i.d. mit $E[X_i] = \mu < \infty$ und $Var[X_i] = \sigma^2 < \infty$, dann:

$$Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0,1)$$

Dann konvergiert die Verteilung der standardisierten Summe gegen die Standardnormalverteilung.

$\Rightarrow E[Z_n] = 0$, $Var[Z_n] = 1$ (im Grenzfall)

d.h. Die Summe ist (asymptotisch) gaußverteilt, unabhangig von der Verteilung der Summanden.

Zufallsfolgen

Definition:

$X_i : \Omega \to \mathbb{R},\ i \in \mathbb{N}$

Bei $N \to \infty$ wäre die vollstandige Beschreibung über die gemeinsame CDF $F_{X_1,\ldots,X_N}(x_1,\ldots,x_N)$ sehr komplex.

Vereinfachungsschritt: *Momente 1./2. Ordnung*

Betrachte Erwartungswertfolge, Varianzfolge und (Auto-)Korrelation/Kovarianz:

- $\mu_X(i) = E[X_i]$ (Erwartungswertfolge)
- $\sigma_X^2(i) = \mathrm{Var}[X_i] = E[X_i^2] - E[X_i]^2$ (Varianzfolge)
- $r_X(k,l) = E[X_k X_l]$ (Autokorrelationsfolge)
- $c_X(k,l) = \mathrm{Cov}[X_k, X_l] = r_X(k,l) - \mu_X(k)\mu_X(l)$
  $= E[(X_k - E[X_k])(X_l - E[X_l])]$ (Autokovarianzfolge)

Zwei Zufallsfolgen X_i, Y_i:

- $r_{XY}(k,l) = E[X_k Y_l]$ (Kreuzkorrelationsfolge)
- $c_{XY}(k,l) = \mathrm{Cov}[X_k, Y_l] = r_{XY}(k,l) - \mu_X(k)\mu_Y(l)$
  $= E[(X_k - E[X_k])(Y_l - E[Y_l])]$ (Kreuzkovarianzfolge)

Orthogonal: $r_{XY}(k,l) = 0$ **Unkorreliert:** $c_{XY}(k,l) = 0$

i.i.d.-Folge: *unabhangig und identisch verteilt*

X_i i.i.d. $\Rightarrow E[X_i] = \mu$, $\mathrm{Var}[X_i] = \sigma^2$, $\mathrm{Cov}[X_i, X_j] = 0\ (i \neq j)$

Stationaritat:

Streng stationar:

$F_{X_{i_1},\ldots,X_{i_m}}(x_1,\ldots,x_m) = F_{X_{i_1+k},\ldots,X_{i_m+k}}(x_1,\ldots,x_m)$

WSS:

$\mu_X(i) = \mu$ konstant, $r_X(k,l) = r_X(k-l)$,
$c_X(k,l) = c_X(k-l)$

$\rightarrow$ **wichtige Relationen:**

stationär $\Rightarrow$ WSS
WSS $\not\Rightarrow$ Stationär

Random Walk:

Definition: mathematisches Modell für eine Folge zufälliger Schritte, um zufallige Prozesse/Bewegungen zu modellieren.

Grundkonzept: Start bei einem Punkt; pro Schritt entweder vorwärts $(+\delta)$ mit Wkt. p oder ruckwarts $(-\delta)$ mit Wkt. $1-p$.

Mathematisch: $n \in \mathbb{N}$ Schritte, $X_i \in \{+\delta, -\delta\}$ (i.i.d.)

- $S_n = \sum_{i=1}^n X_i$, für kleine und große n nicht stationär
- $P(\{X_i = +\delta\}) = p$, • $P(\{X_i = -\delta\}) = 1-p$
- $E[X_i] = (2p-1)\delta$, • $\mathrm{Var}[X_i] = 4p(1-p)\delta^2$
- $\mu_S(n) = E[S_n] = n(2p-1)\delta$
- $\sigma_S^2(n) = \mathrm{Var}[S_n] = 4np(1-p)\delta^2$

Fur $p = \frac{1}{2}$ gilt: $\mu_S(n) = 0$ und $\sigma_S^2(n) = n\delta^2$.

Markovketten und bedingte Unabhangigkeit

Markov-Ungleichung:

Abschatzung fur große Ausschlage einer ZV:

$P(\{|X| \geq a\}) \leq \frac{E[|X|]}{a}, \quad a > 0$

Tschebyschow-Ungleichung:

$P(\{|X - E[X]| \geq a\}) \leq \frac{\mathrm{Var}[X]}{a^2}, \quad a > 0$
$\Rightarrow P(\{|X - E[X]| < a\}) \geq 1 - \frac{\mathrm{Var}[X]}{a^2}$

Bedingte Unabhangigkeit:

Ereignisse A, C sind bedingt unabhangig bzgl. B, wenn

$P(A \cap C \mid B) = P(A \mid B) P(C \mid B)$
$\Leftrightarrow P(A \mid B \cap C) = P(A \mid B)$
$\Leftrightarrow P(C \mid B \cap A) = P(C \mid B)$

Achtung: i.A. gilt nicht $P(A \cap C) = P(A)P(C)$.

Fur Zufallsvariablen/pdf/pmf:

$p_{X,Z|Y}(x,z \mid y) = p_{X|Y}(x \mid y)\, p_{Z|Y}(z \mid y)$
$p_{Z|Y,X}(z \mid y,x) = p_{Z|Y}(z \mid y)$
$f_{Z|Y,X}(z \mid y,x) = f_{Z|Y}(z \mid y)$
$f_{X,Z|Y}(x,z \mid y) = f_{X|Y}(x \mid y) \cdot f_{Z|Y}(z \mid y)$

$\Rightarrow \quad \frac{f_{X_1,X_2,X_3}(x_1,x_2,x_3)}{f_{X_1,X_2}(x_1,x_2)} = \frac{f_{X_2,X_3}(x_2,x_3)}{f_{X_2}(x_2)}$

$\Rightarrow \quad \frac{f_{X_1,X_2,X_3}(x_1,x_2,x_3)}{f_{X_2,X_3}(x_2,x_3)} = \frac{f_{X_1,X_2}(x_1,x_2)}{f_{X_2}(x_2)}$

Markov-Eigenschaft:

$P(X_{n+1} = x_{n+1} \mid X_n, \ldots, X_1) = P(X_{n+1} = x_{n+1} \mid X_n)$

Beispiel (1. Ordnung): $f_{X_3|X_2,X_1}(x_3 \mid x_2, x_1) = f_{X_3|X_2}(x_3 \mid x_2)$

Homogene Markovkette:

$p_{ij} = P(X_{n+1} = j \mid X_n = i)$ ist unabhangig vom Index n.

Zustandsubergang / Matrix:

Ubergangsmatrix: $\Pi = [p_{ij}]$, $p_{ij} \in [0,1]$, $\sum_j p_{ij} = 1$

m-Schritt-Ubergange: $p_{ij}^{(m)} = P(X_{n+m} = j \mid X_n = i) = [\Pi^m]_{ij}$

Zustandsvektor:

$\underline{p}_{n+1} = \underline{p}_n \Pi, \quad \underline{p}_{n+m} = \underline{p}_n \Pi^m$

Stationare Verteilung:

$\underline{\pi} = \underline{\pi}\Pi, \quad \sum_i \pi_i = 1$

Bei endlichem, irreduziblem und aperiodischem Zustandraum ist $\underline{\pi}$ eindeutig und $\underline{p}_n \to \underline{\pi}$.

Reelle Zufallsprozesse

Grundgroßen:

$\mu_X(t) = E[X_t]$
$\sigma_X^2(t) = \mathrm{Var}[X_t]$
$r_X(t,s) = E[X_t X_s]$
$c_X(t,s) = \mathrm{Cov}[X_t, X_s] = r_X(t,s) - \mu_X(t)\mu_X(s)$

Gemeinsame Prozesse X_t, Y_t:

$r_{XY}(t,s) = E[X_t Y_s]$
$c_{XY}(t,s) = r_{XY}(t,s) - \mu_X(t)\mu_Y(s)$

WSS-Prozess:

$\mu_X(t) = \mu_X$ konstant, $r_X(t,s) = r_X(t-s)$,
$c_X(t,s) = c_X(t-s)$

Orthogonalitat / Unkorreliertheit:

Orthogonal: $r_{XY}(t,s) = 0$
Unkorreliert: $c_{XY}(t,s) = 0$

Wiener-Prozess (kurz):

$W_t \sim N(0, \sigma^2 t), \quad E[W_t] = 0, \quad \mathrm{Var}[W_t] = \sigma^2 t,$
$r_W(s,t) = \sigma^2 \min(s,t)$ und unabhangige Inkremente.

Poisson Prozess

Definition:

N_t: Anzahl Ereignisse in $[0,t]$ mit Rate $\lambda > 0$.
$N_t \sim \mathrm{Pois}(\lambda t)$
$P(N_t = n) = \frac{(\lambda t)^n}{n!} e^{-\lambda t},\ n \in \mathbb{N}_0$

$\rightarrow$ **Eigenschaften:**

- $E[N_t] = \lambda t$
- $\mathrm{Var}[N_t] = \lambda t$
- $r_N(s,t) = \lambda \min(s,t) + \lambda^2 st$
- $c_N(s,t) = \lambda \min(s,t)$
- $Inkrementesindunabhangigundstationar$
- $X_i \sim \mathrm{Exp}(\lambda)$ (Wartezeiten, i.i.d.)

Leistungsdichtespektrum und LTI-Systeme

LTI-System:

$y(t) = (h * x)(t) = \int_{-\infty}^{\infty} h(\tau) x(t-\tau)\, d\tau$
$Y(f) = H(f) X(f)$

Bei WSS-Eingang:

$\mu_Y = \mu_X \int h(t)\, dt = \mu_X H(0)$
$r_{YY}(\tau) = (h * \tilde{h} * r_{XX})(\tau)$, $\tilde{h}(t) = h(-t)$

Leistungsdichte (LDS):

$S_{YY}(f) = |H(f)|^2 S_{XX}(f)$
$S_{XY}(f) = H(f) S_{XX}(f), \quad S_{YX}(f) = H^*(f) S_{XX}(f)$

Allgemein fur WSS-Prozesse:

- $S_X(f) \geq 0$
- $S_X(-f) = S_X(f)$ fur reelle Prozesse
- $\int_{-\infty}^{\infty} S_X(f)\, df = \mathrm{Var}[X] + \mu_X^2$